Репликация данных и согласованность

Олег Сухорослов

Распределенные системы

Факультет компьютерных наук НИУ ВШЭ

7.11.2022

План

- Репликация данных, известные подходы к реализации
- Согласованность, связь с репликацией, известные модели

Репликация данных

Хранение физических копий (реплик) данных на нескольких машинах (файлы, записи, конфигурация, состояние процессов)

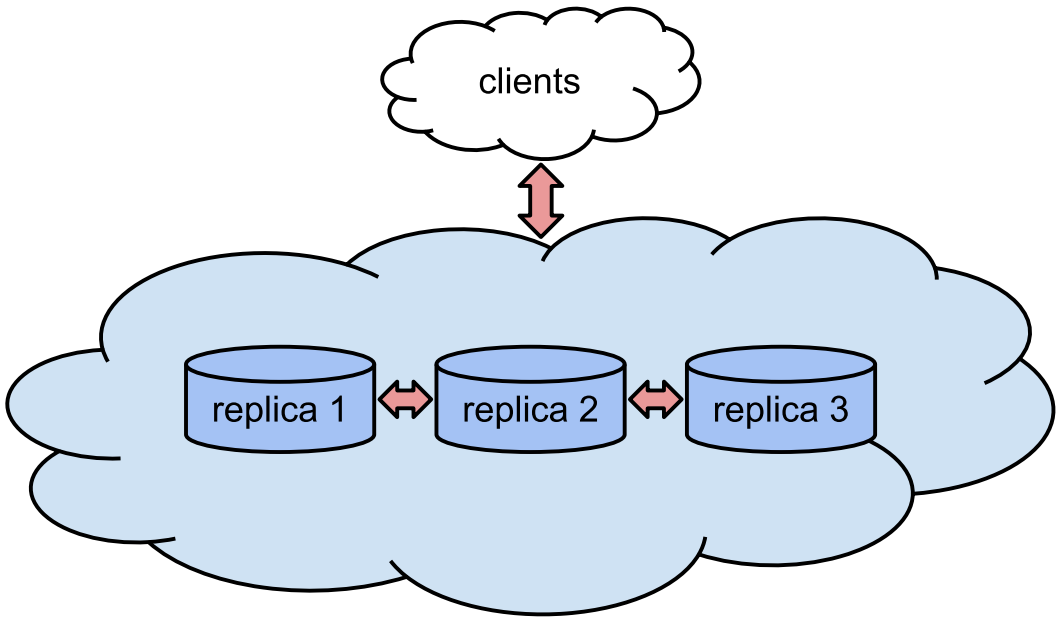

Мотивация

- Повышение доступности
- Уменьшение задержки
- Увеличение производительности

replicas n	$P(\geq 1$ faulty$)$	$P(\geq \frac{n+1}{2}$ faulty$)$	$P($all n faulty$)$
1	0.01	0.01	0.01
3	0.03	$3 \cdot 10^{-4}$	10^{-6}
5	0.049	$1 \cdot 10^{-5}$	10^{-10}
100	0.63	$6 \cdot 10^{-74}$	10^{-200}

Kleppmann M. Distributed Systems

Характер данных и операции

- Неизменяемые данные
  - После записи данные не модифицируются (write once, read many)
  - Пример: хранение логов
  - Репликация реализуется легко
- Изменяемые данные
  - Операции write и read к любым элементам данных в любое время (в т.ч. одновременно)
  - Пример: база данных
  - Проблемы: синхронизация реплик, обеспечение согласованности

Согласованность (consistency)

- Какие **гарантии** требуются от системы с несколькими репликами данных и одновременно работающими клиентами?
- **Сильная согласованность**: система с точки зрения клиентов не отличима от одного сервера
  - При работе с системой не наблюдаются "аномалии", нарушающие привычные гарантии
- **Пример**: чтение значения по ключу k всегда возвращает последнее записанное по этому ключу значение
  - Что такое "последнее записанное значение"?
  - Что делать, если значения реплик "разошлись"?

Активная и пассивная репликация

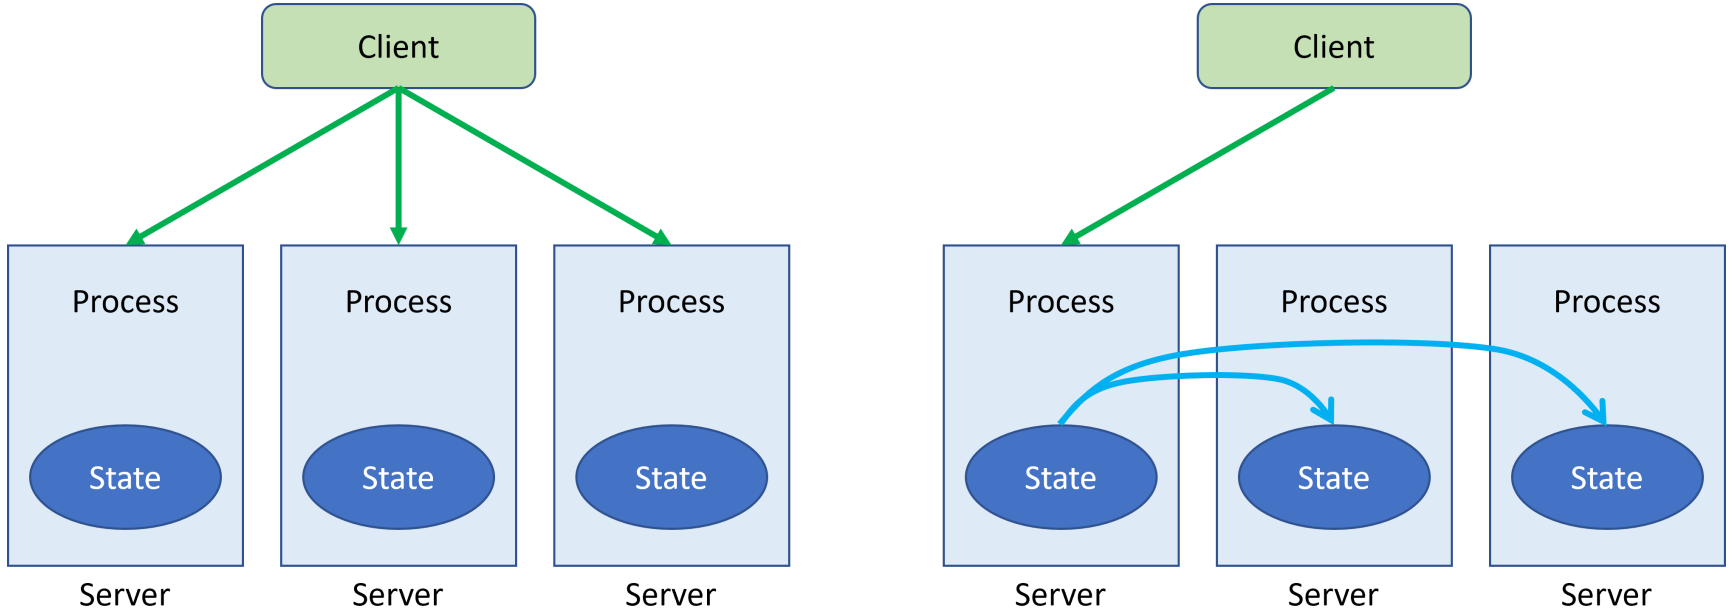

- **Активная репликация**: серверы равноправны, запросы клиентов обрабатываются каждым сервером
- **Пассивная репликация**: один выделенный сервер, обрабатывающий запросы клиентов и передающий изменения остальным

Синхронная и асинхронная репликация

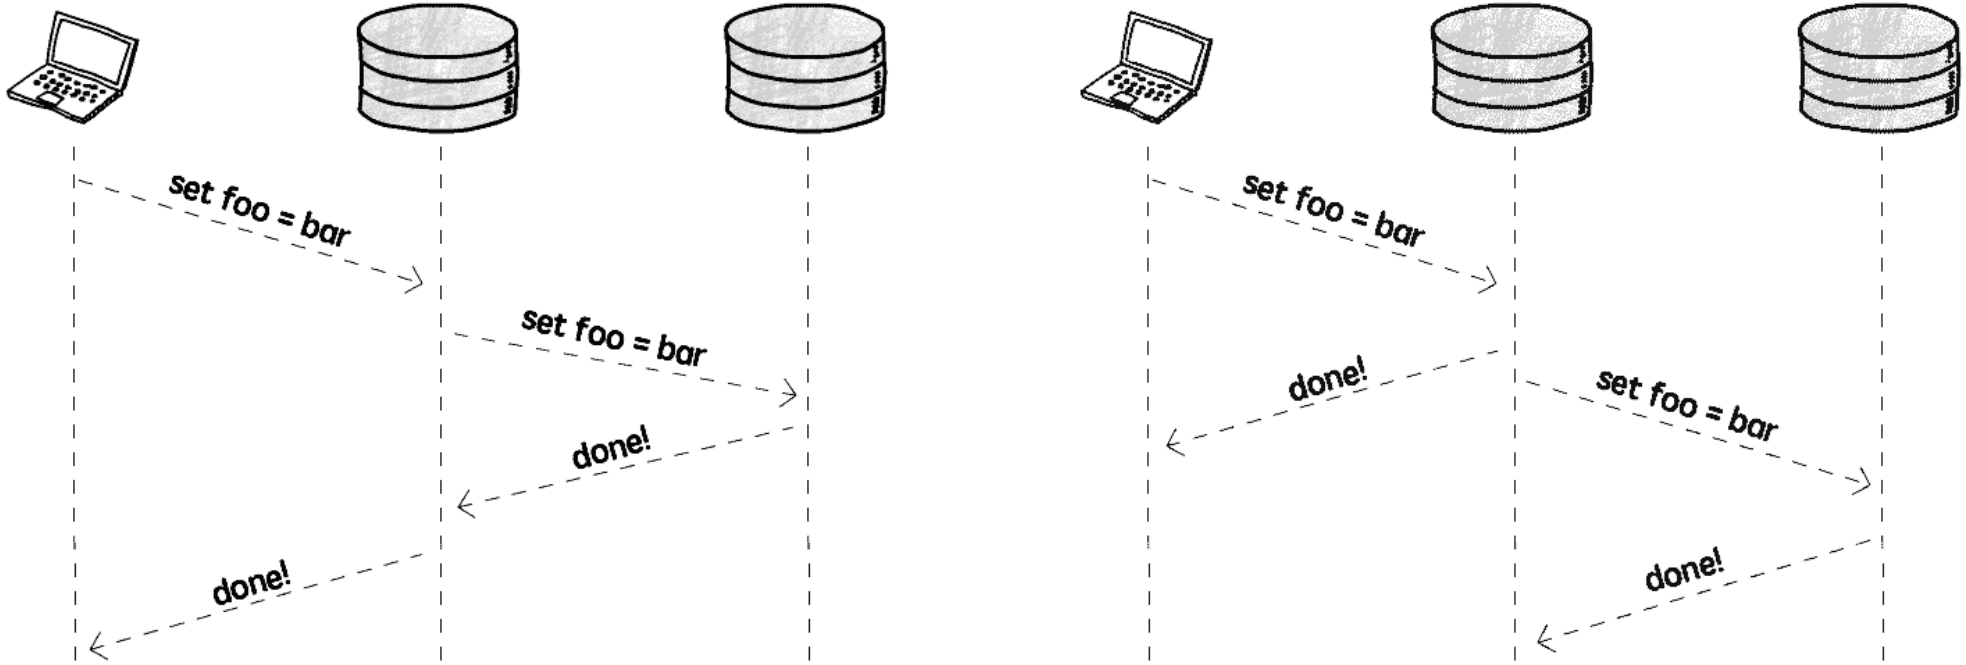

Какие здесь возникают компромиссы?

Основные подходы к репликации

- **Репликация с одним лидером** (active/passive, master-slave)
  - Запись данных ведется только через один узел
  - PostgreSQL, MySQL, Oracle, MongoDB, HBase, Kafka
- **Репликация с несколькими лидерами** (active/active, multi-master)
  - Клиент производит запись через одного из нескольких лидеров
  - WANdisco, CouchDB, Google Docs
- **Репликация без лидеров** (leaderless, quorum)
  - Клиент производит чтение и запись, взаимодействуя с несколькими узлами
  - Dynamo, Riak, Cassandra, Voldemort

Репликация с одним лидером

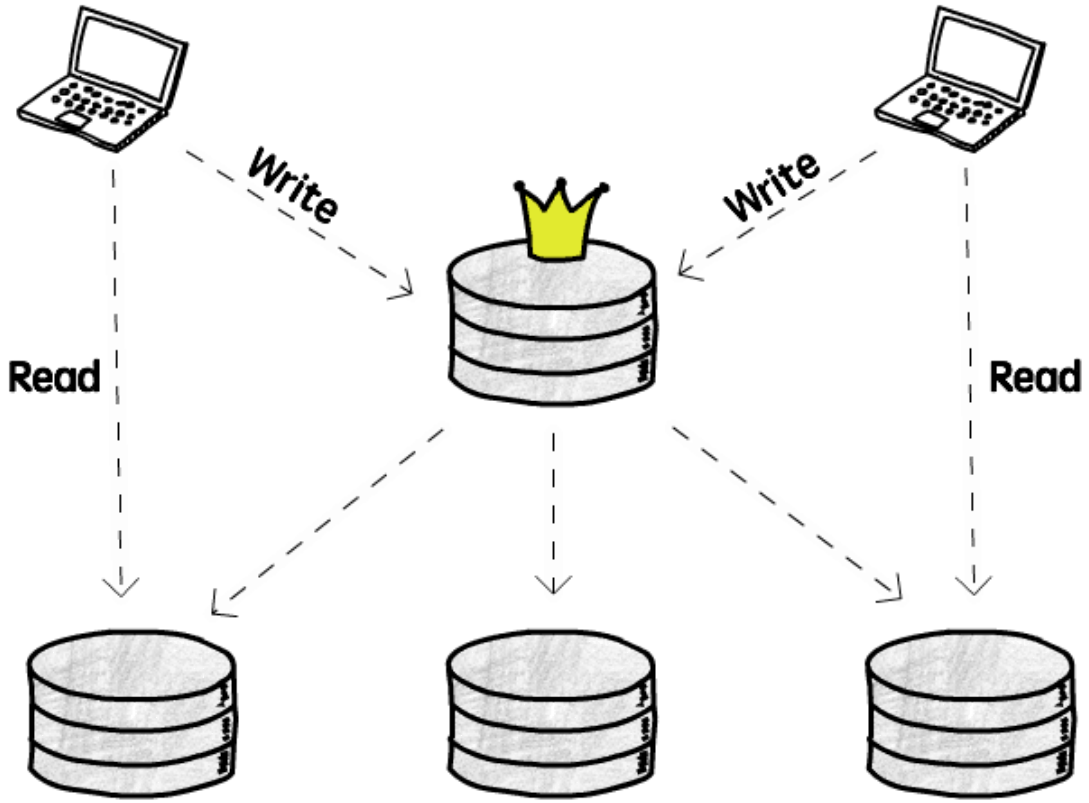

Репликация с одним лидером

- Сихронная или асинхронная
  - Компромиссы (задержка, согласованность, надежность, доступность)
  - Полусинхронная репликация
- Что передается между лидером и подчиненными?
  - Операции, запросы (statement-based replication)
  - Результаты обработки операций (log shipping, row-based replication)
- Подключение новой реплики
  - Копирование данных с лидера на некоторый момент времени (snapshot)
  - Применение последующих изменений (catch up)

Репликация с одним лидером

- Отказ подчиненного узла (catch-up recovery)
  - Перезапуск и получение актуального состояния
- Отказ лидера (failover)
  - Выбор нового лидера и реконфигурация системы
  - Ручная или автоматическая процедура
  - Перенаправление клиентов на нового лидера (request routing)
  - Возвращение старого лидера, техника STONITH, разделение сети (split brain)

Разделение сети (network partition)

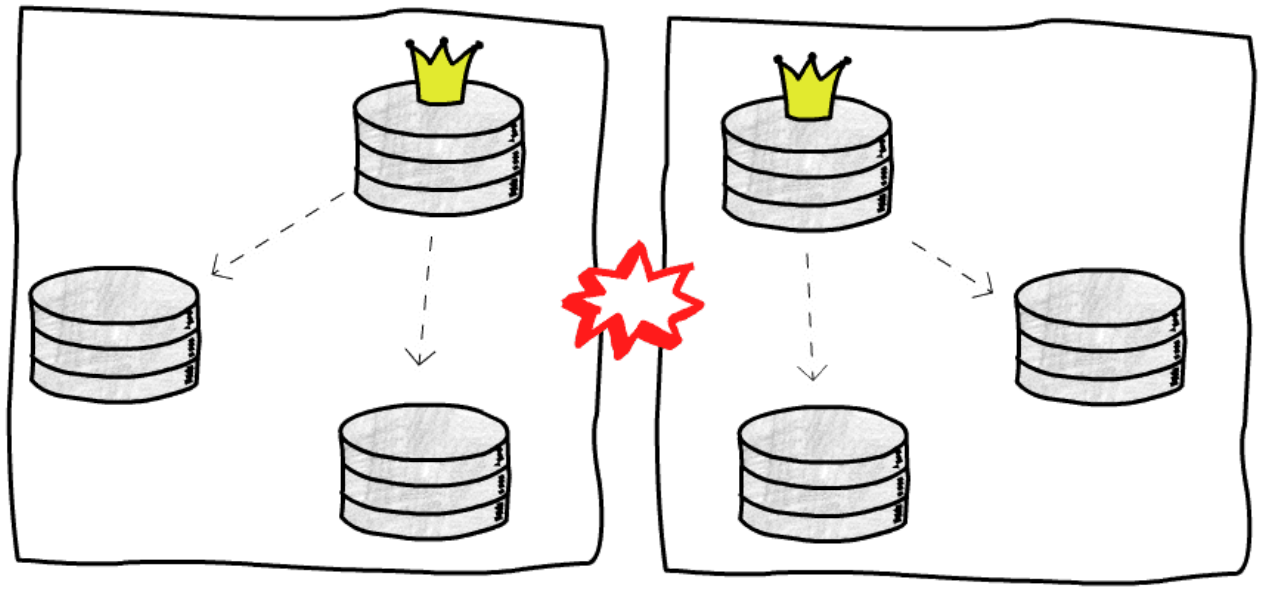

Репликация с одним лидером

- Преимущества
  - Отсутствие конфликтов, т.к. лидер упорядочивает операции записи
  - Простота реализации
- Недостатки
  - Ограниченная масштабируемость (в т.ч. гео-)
  - Необходимость обработки отказов (выборов) лидера

Репликация с несколькими лидерами

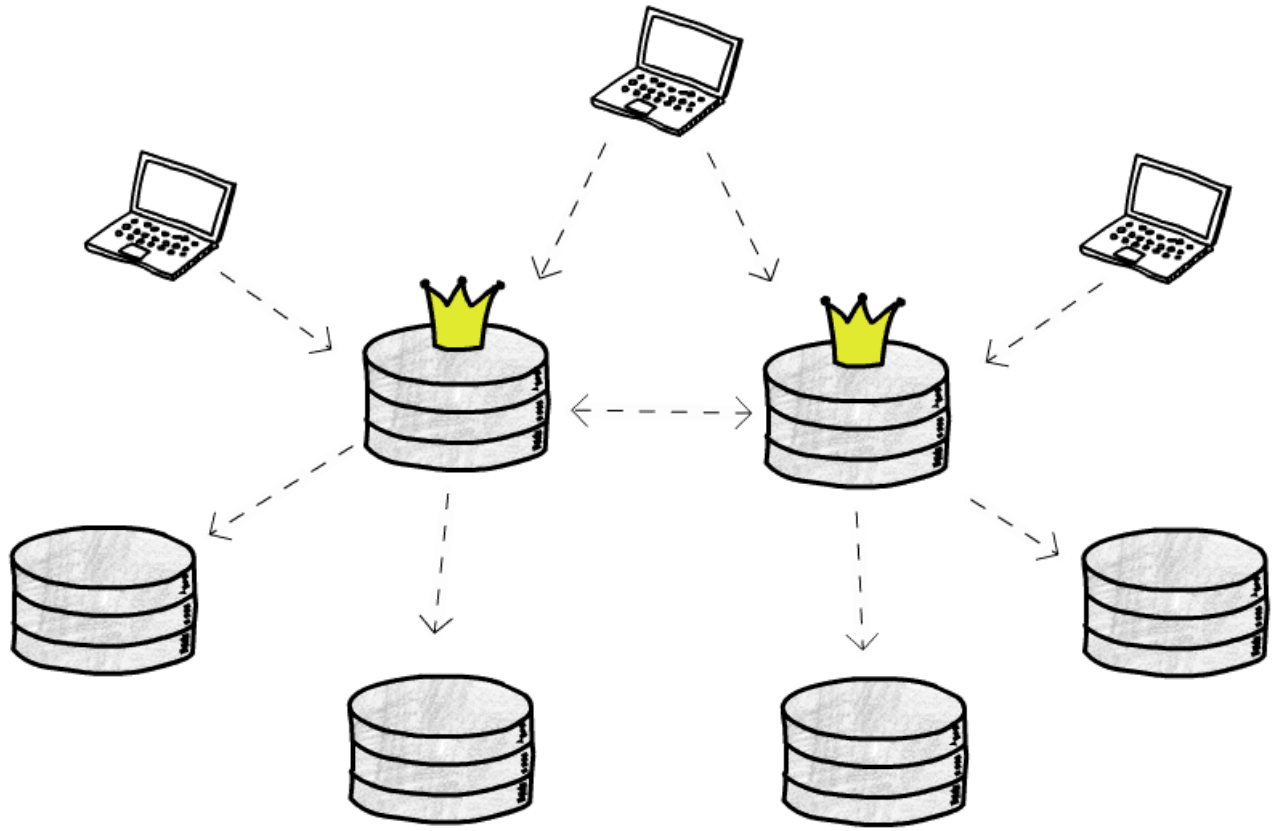

Репликация с несколькими лидерами

- Операции записи обрабатывают несколько узлов-лидеров
  - Клиент взаимодействует с одним лидером
  - Лидер также играет роль подчиненного относительно других лидеров
- Мотивация
  - Репликация данных между датацентрами (задержка, доступность, WANdisco)
  - Функционирование в офлайн-режиме (календарь, Dropbox, CouchDB)
  - Онлайн-сервисы совместного редактирования (Google Docs)

Асинхронный режим

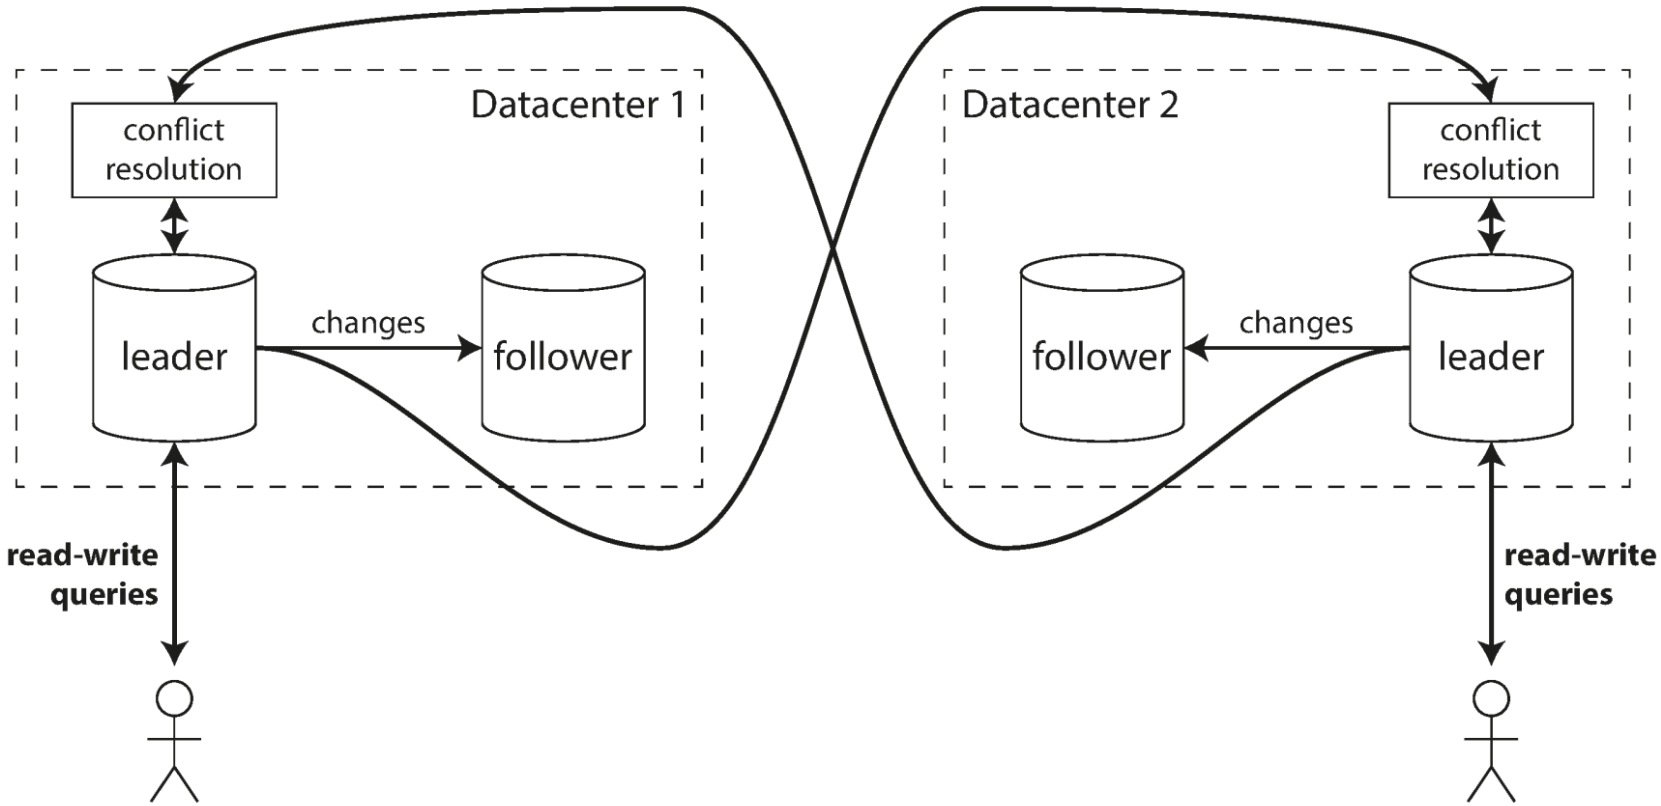

Конфликт при записи данных

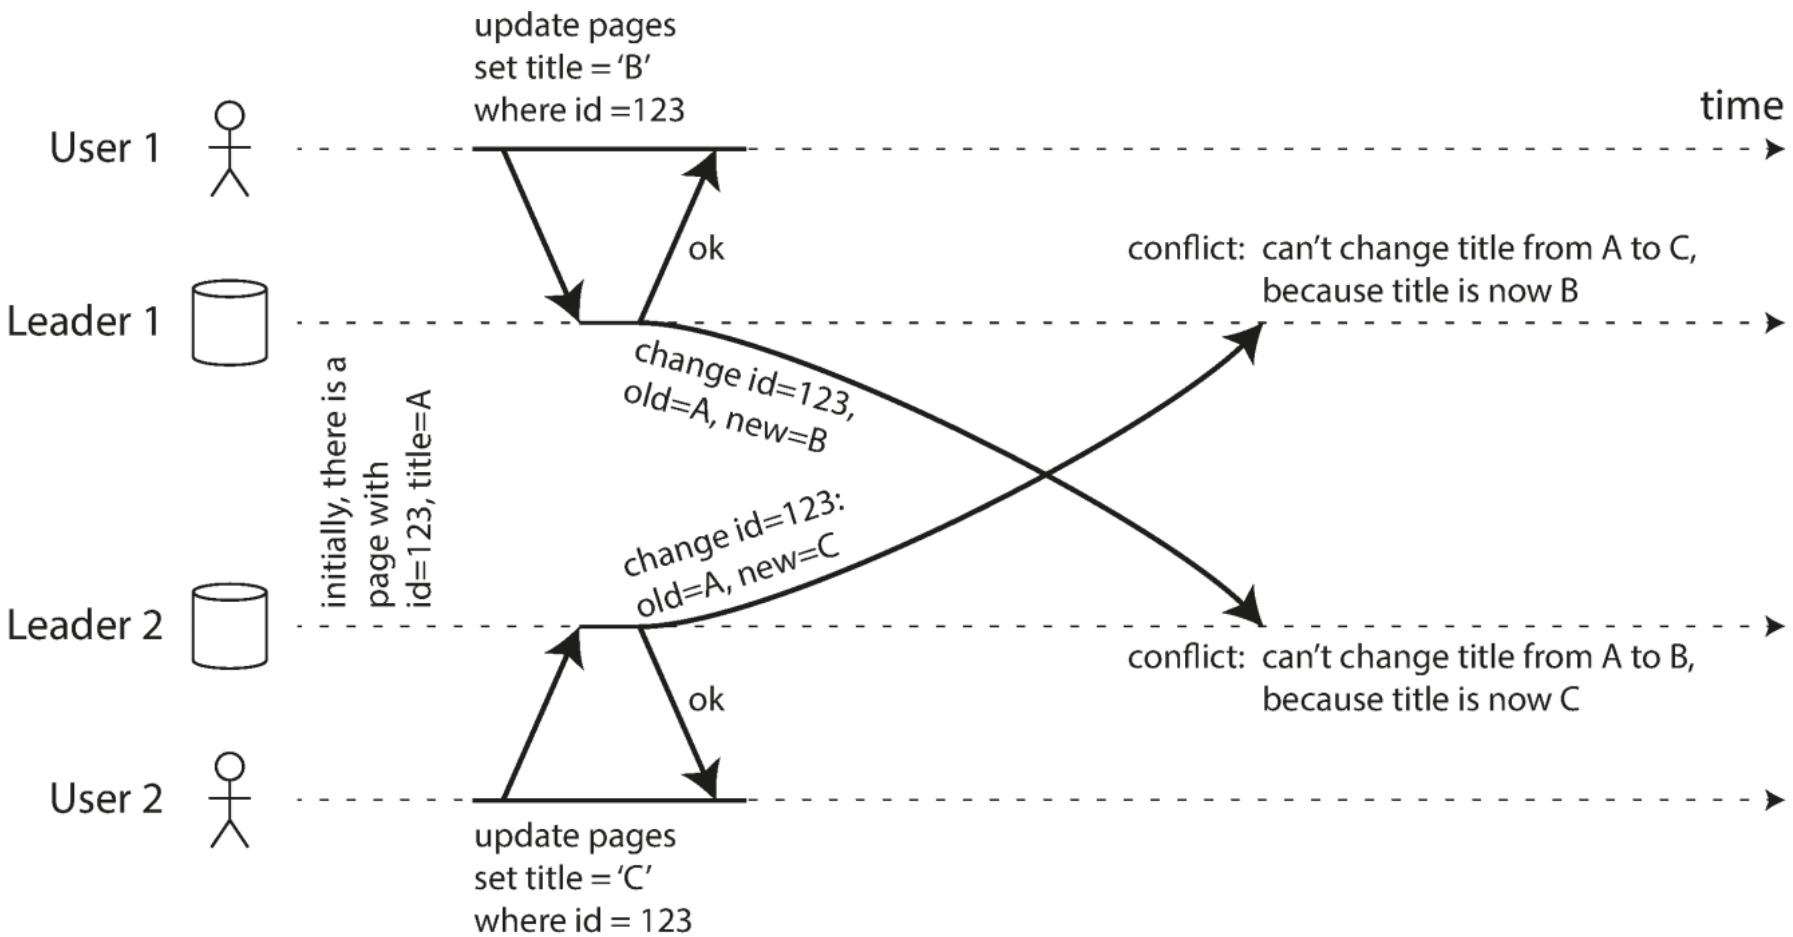

Разрешение конфликтов

- Требуется обеспечить свойство сходимости (convergence)
  - Все реплики должны прийти к общему конечному значению после того, как все изменения достигнут всех узлов
- Возможные подходы
  - Операция с наибольшим ID "выигрывает" (last write wins)
  - Слияние конфликтующих значений ("B/C")
  - Специфическая процедура на уровне приложения, в т.ч. с участием пользователя
  - Conflict-free replicated data types (CRDT)
- Когда происходит разрешение конфликта?
  - Во время записи или чтения

Нарушение порядка операций записи

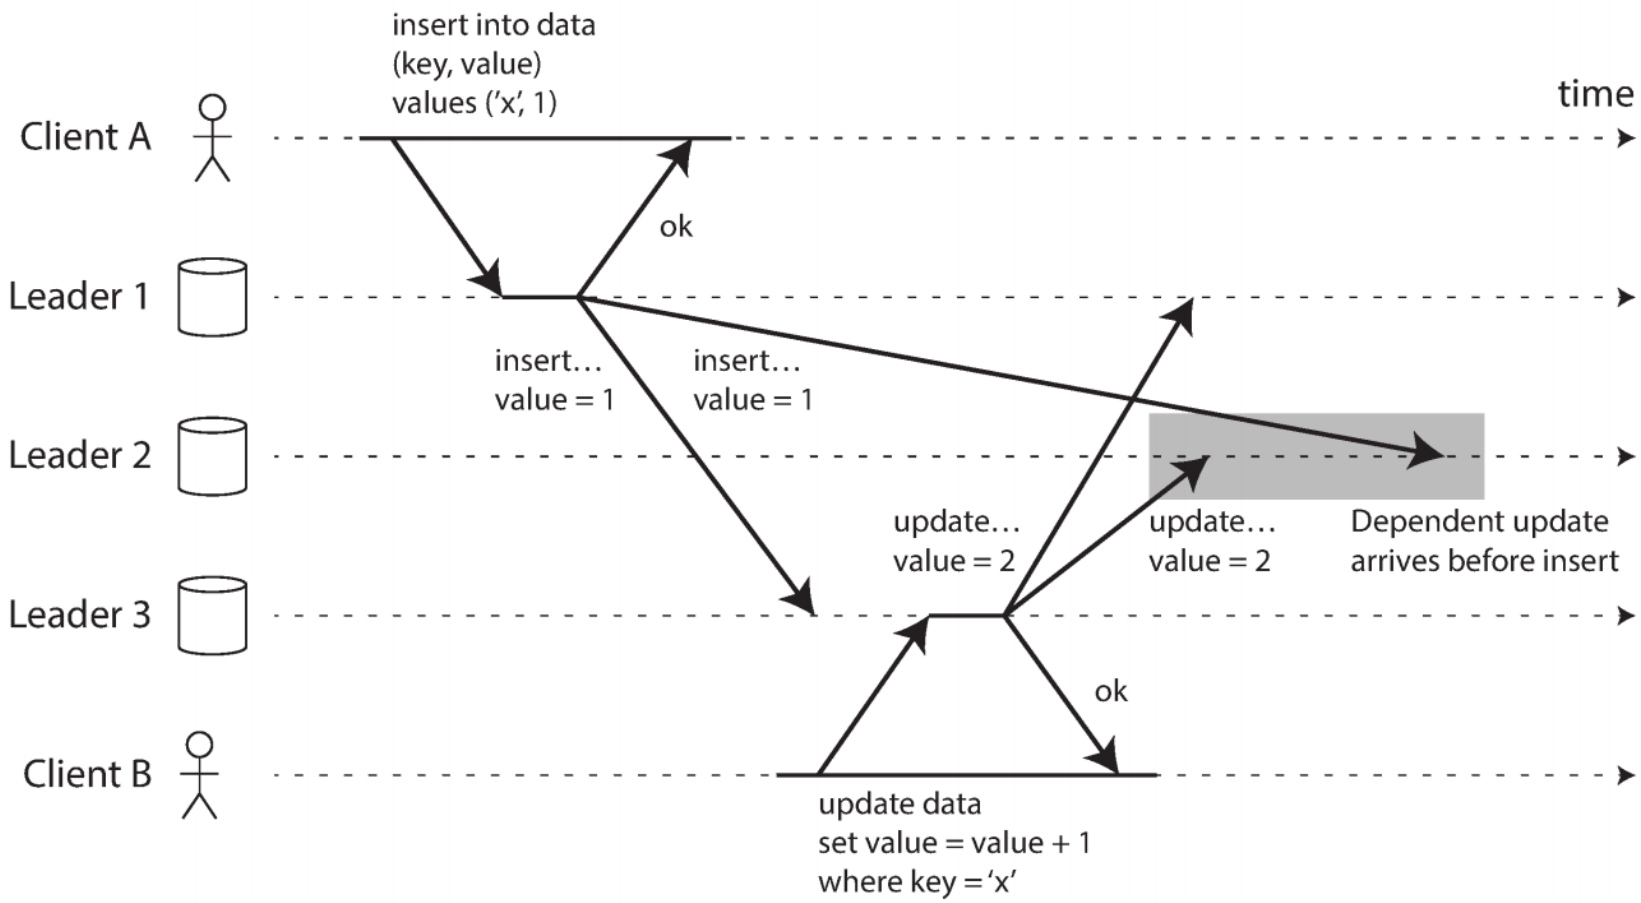

Репликация с несколькими лидерами

- Преимущества
  - Распределение нагрузки между несколькими лидерами
  - Снижение задержки для географически распределенных клиентов
  - Поддержка офлайн-клиентов
- Недостатки
  - Требуется координация между лидерами (синхронный режим)
  - Возможны конфликты при записи (асинхронный режим)
  - Возможно нарушение порядка операций записи

Репликация без лидера

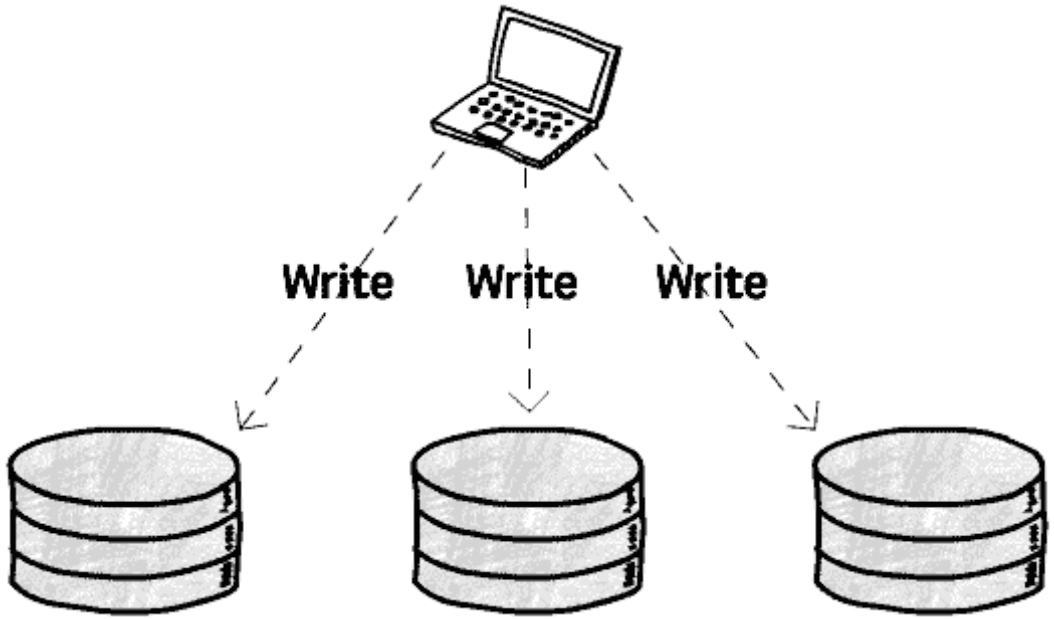

Репликация без лидера

- Клиент взаимодействует не с одним узлом (лидером), а с несколькими
  - Узлы не копируют активно данные между друг другом
  - Клиент сам отвечает за копирование данных
- Операции чтения и записи требуют взаимодействия клиента с R и W узлами (запись и чтение с кворумом)
- Gifford D.K. Weighted Voting for Replicated Data (1979)
- Примеры: Dynamo, Riak, Cassandra, Voldemort

Запись и чтение с кворумом

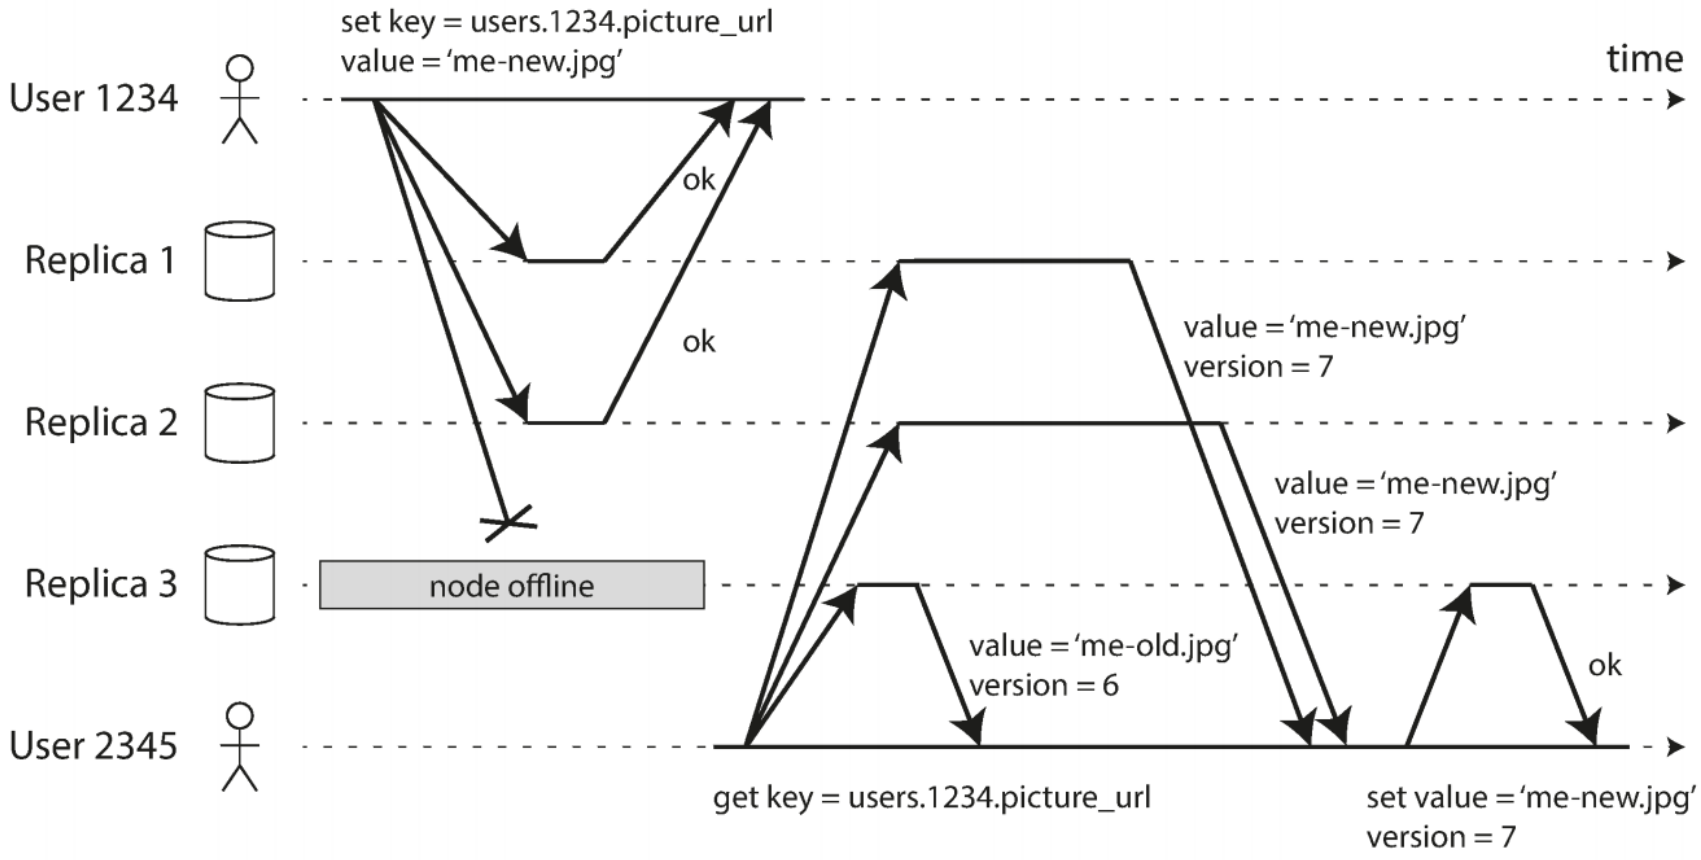

Размеры кворумов

- Для чтения последних записанных данных необходимо, чтобы $W + R > N$
- Во многих системах параметры W, R, N можно настраивать
  - N — нечетное
  - $W = R = (N + 1)/2$ — сбалансированная конфигурация
  - $W = N,\ R = 1$ — максимальная оптимизация под чтение
- Усточивость к отказам
  - $W < N,\ R < N$
  - $N = 3,\ W = 2,\ R = 2$ — допустим отказ 1 узла
  - $N = 4,\ W = 3,\ R = 2$ — допустим отказ 1 узла
  - $N = 5,\ W = 3,\ R = 3$ — допустимы отказы 2 узлов

Пример: N=5 W=3 R=3

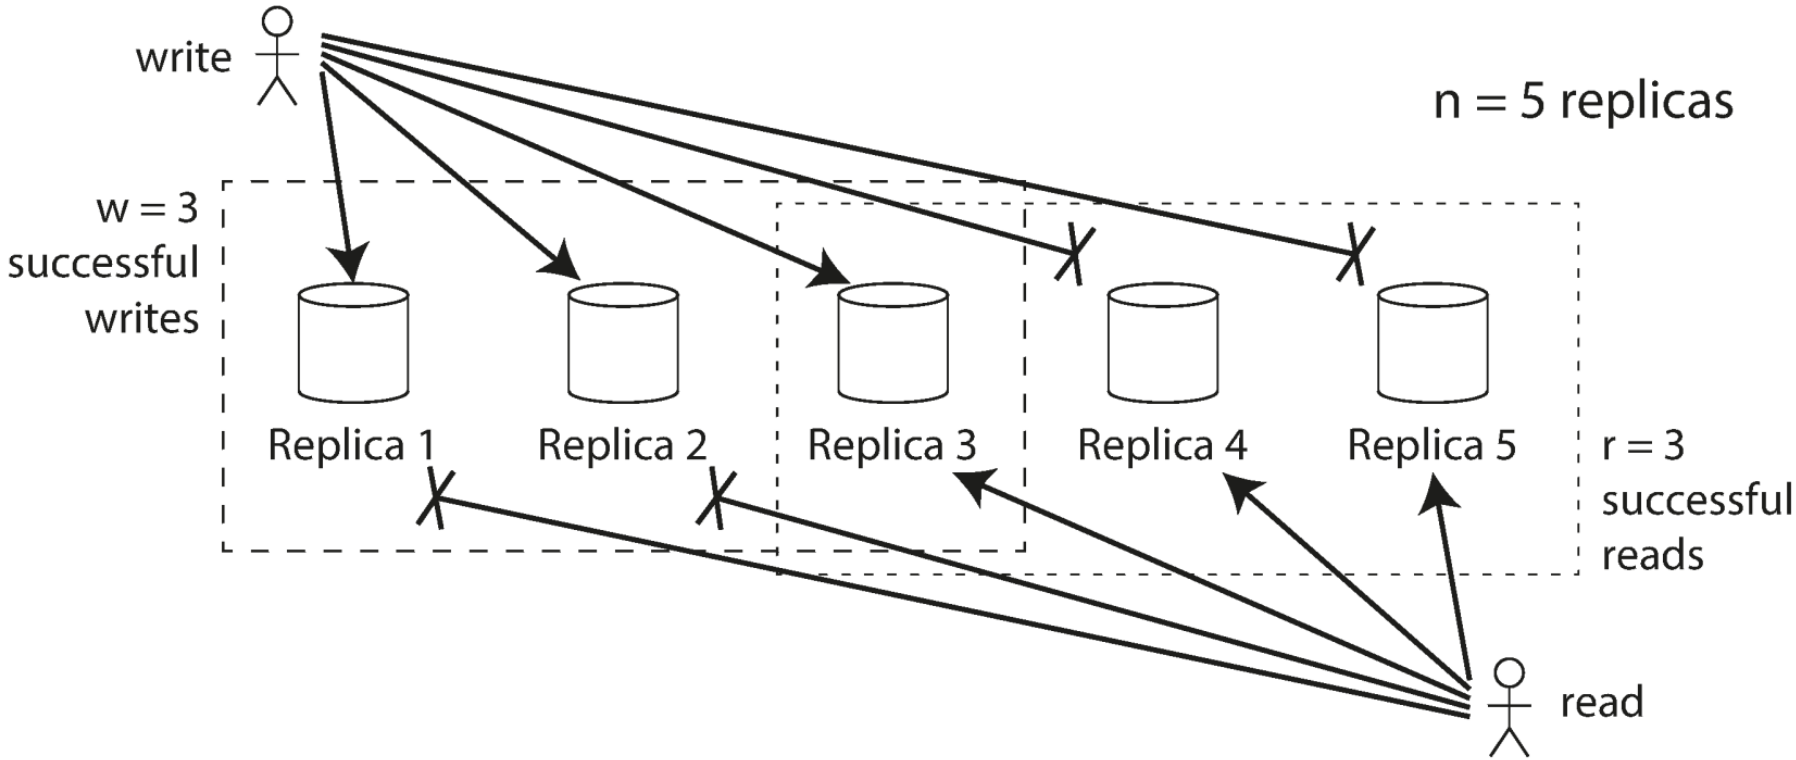

Дополнительные механизмы

- Read repair
  - Обновление устаревших данных и разрешение конфликтов во время чтения
- Anti-entropy
  - Фоновый процесс, постоянно осуществляющий обмен информацией и сравнение хранимых данных между репликами
- Sloppy quorum, hinted handoff
  - Временный перенос функций реплик с отказавших на другие узлы
- См. Dynamo: Amazon's Highly Available Key-value Store (2007)

Репликация без лидера

- Преимущества
  - Упрощается обработка отказов (не надо выбирать лидера)
  - Потенциально высокая доступность
  - Проще архитектура?
- Недостатки
  - Сложнее обеспечивать согласованность данных
  - Возможно возникновение конфликтов
  - Требуются дополнительные механизмы для восстановления согласованности и разрешения конфликтов

Репликация и рассылка

- Можно ли использовать известные нам варианты рассылки для репликации?
- Какие требования должны предъявляться к рассылаемым операциям?

broadcast	assumptions about state update function
total order	deterministic (SMR)
causal	deterministic, concurrent updates commute
reliable	deterministic, all updates commute
best-effort	deterministic, commutative, idempotent, tolerates message loss

Kleppmann M. Distributed Systems

Согласованность (consistency)

- Какие **гарантии** требуются от системы с несколькими репликами данных и одновременно работающими клиентами?
  - В любой момент времени все реплики хранят одинаковое значение
  - Каждое чтение возвращает последнее записанное значение
  - Некоторые гарантии на порядок и видимость результатов операций
- **Модель согласованности** определяется набором предоставляемых гарантий
  - Клиенты системы не должны наблюдать "аномалии", в которых эти гарантии нарушаются
- Aguilera M., Terry D. The many faces of consistency (2016)

Аномалия 1

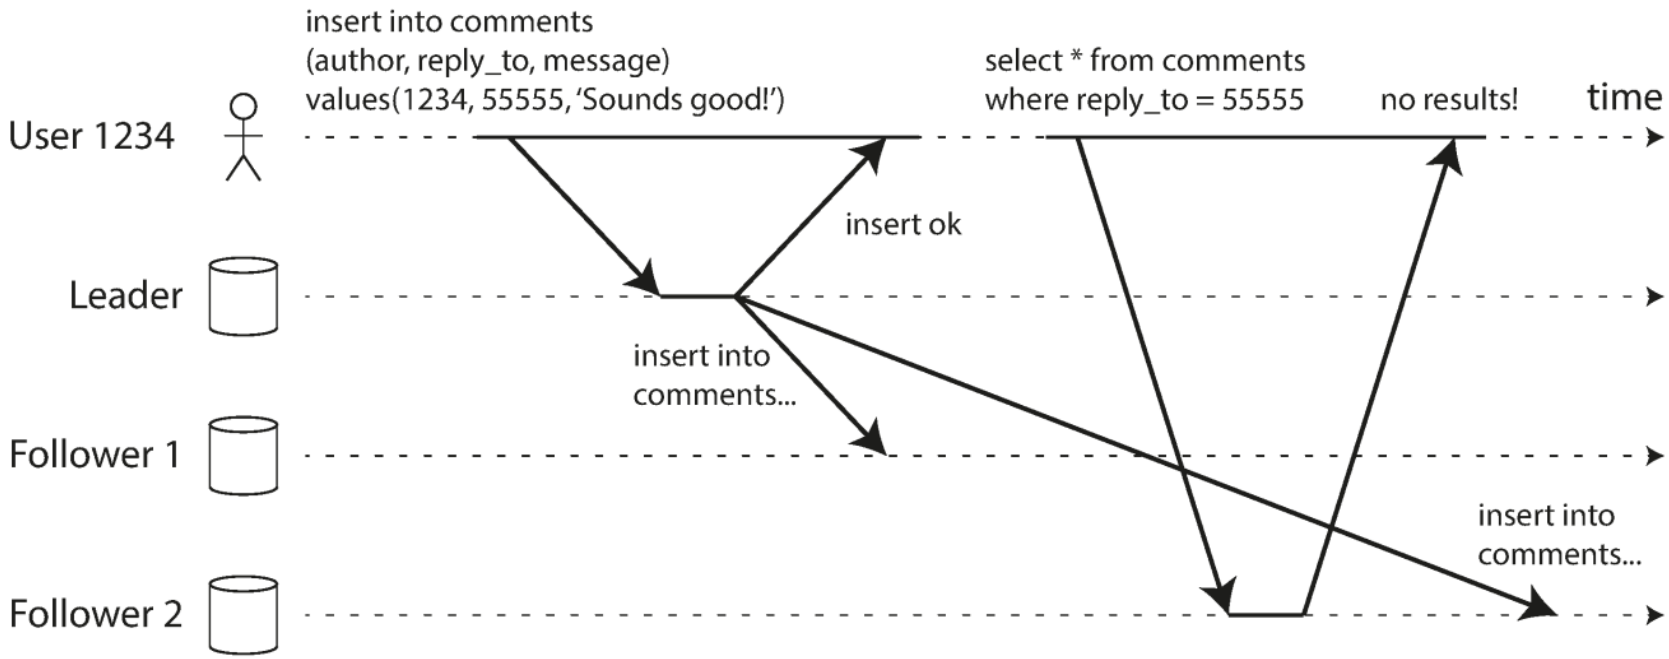
insert into comments
(author, reply_to, message)
values(1234, 55555, 'Sounds good!')
select * from comments
where reply_to = 55555
no results!
time
User 1234
insert ok
Leader
insert into
comments...
Follower 1
insert into
comments...
Follower 2

Аномалия 2

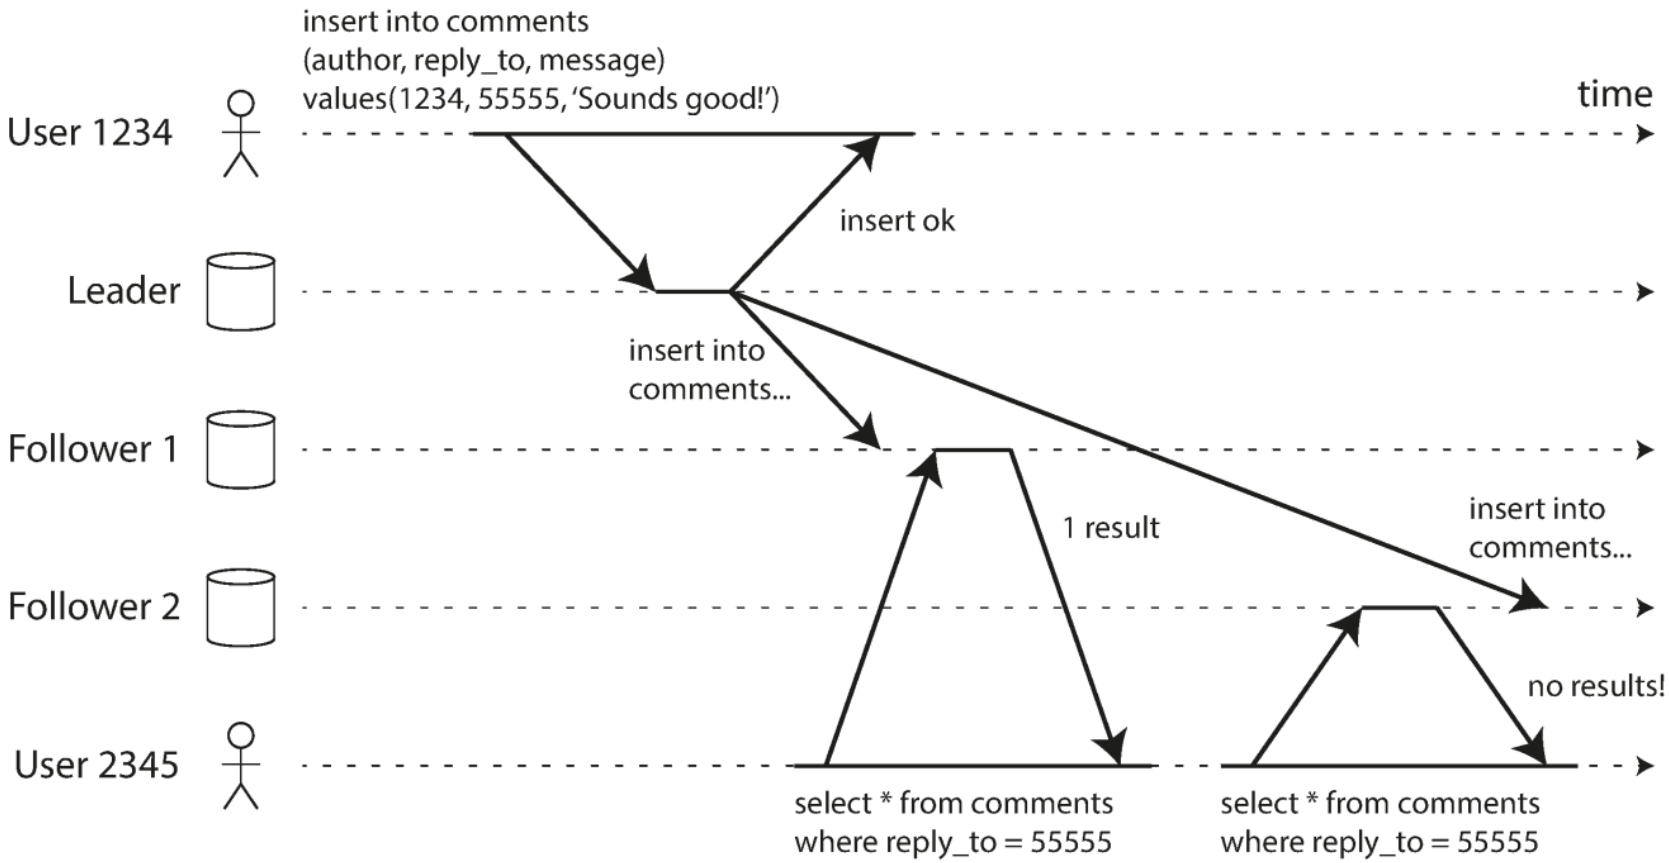
insert into comments
(author, reply_to, message)
values(1234, 55555, 'Sounds good!')
time
User 1234
insert ok
Leader
insert into
comments...
Follower 1
1 result
insert into
comments...
Follower 2
no results!
User 2345
select * from comments
where reply_to = 55555
select * from comments
where reply_to = 55555

Аномалия 3

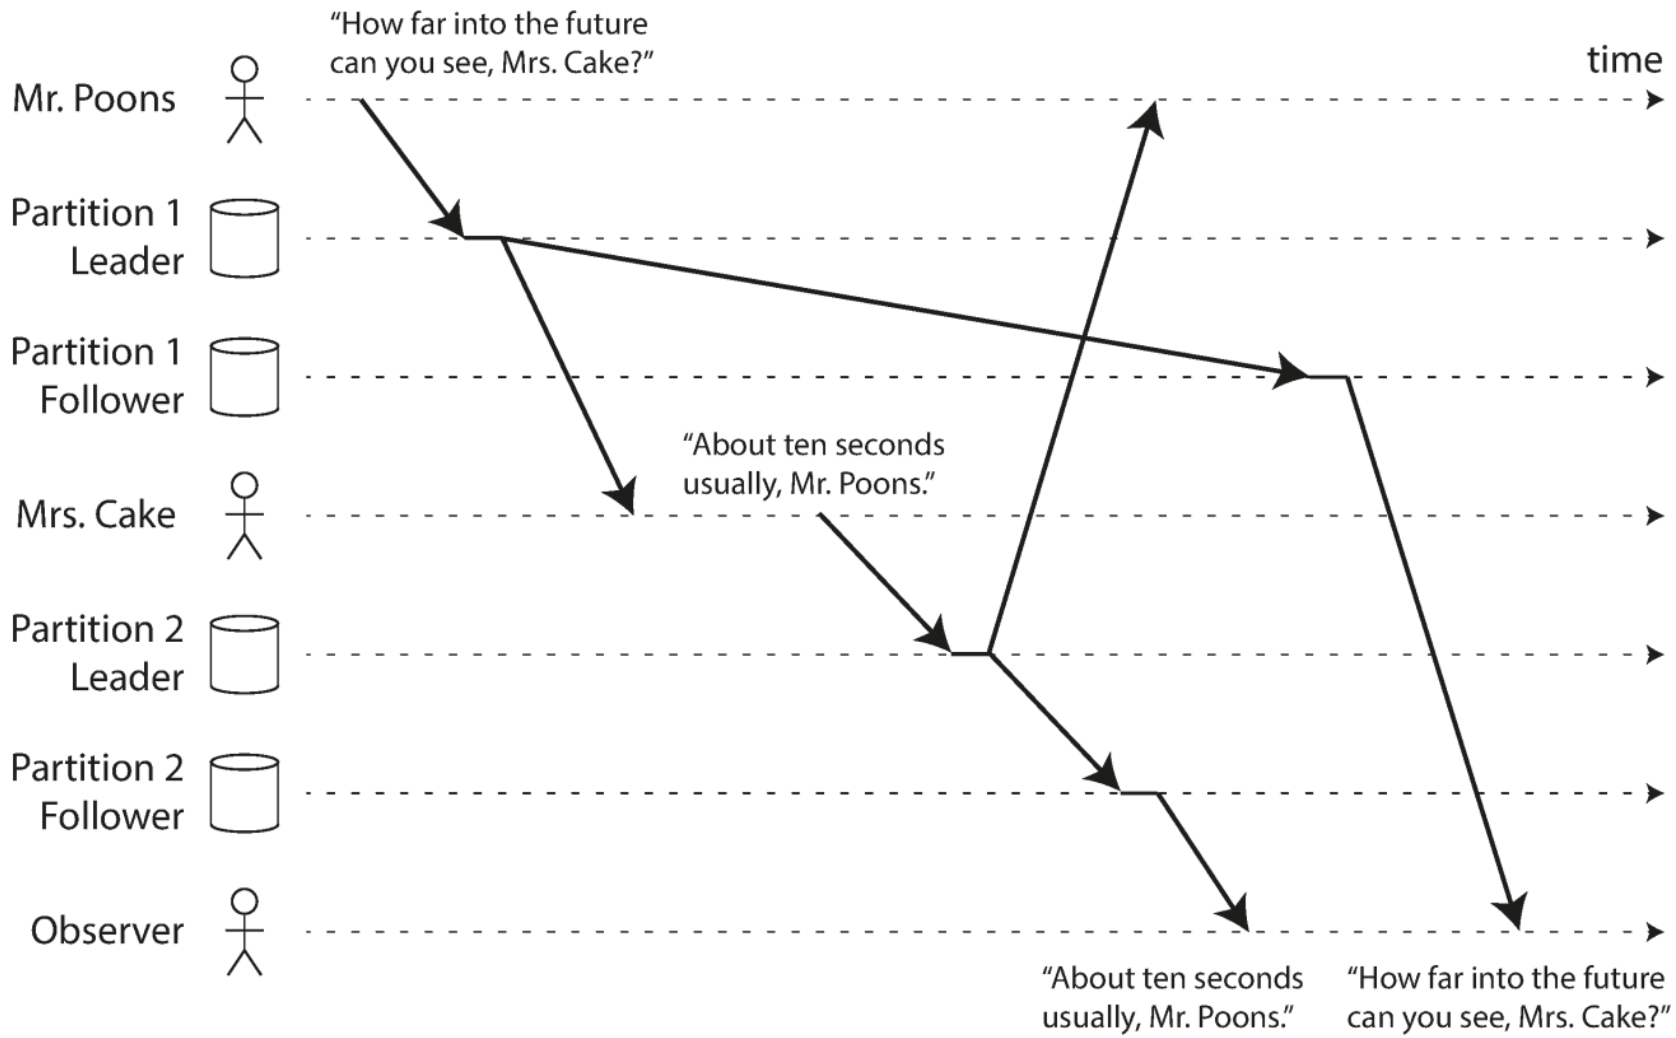
"How far into the future
can you see, Mrs. Cake?"
time
Mr. Poons
Partition 1
Leader
Partition 1
Follower
"About ten seconds
usually, Mr. Poons."
Mrs. Cake
Partition 2
Leader
Partition 2
Follower
Observer
"About ten seconds
usually, Mr. Poons."
"How far into the future
can you see, Mrs. Cake?"

Модель согласованности

- Результаты каких операций записи "видны" клиенту?
- Всех предыдущих операций в соответствии с некоторым единым порядком
  - Строгая согласованность, линеаризуемость, последовательная согласованность
- Любого подмножества операций в произвольном порядке
  - Согласованность в конечном счёте (eventual)
- Промежуточные модели между этими двумя крайностями

Строгая согласованность

- Чтение всегда возвращает результат самой последней записи
- Результат записи становится мгновенно доступен всем клиентам
- Не реализуема на практике в силу законов физики

Линеаризуемость

> Herlihy M.P., Wing J.M. Linearizability: A correctness condition for concurrent objects (1990)

- Наиболее строгая модель из реализуемых на практике
- Любое выполнение системы может быть представлено в виде некоторой упорядоченной истории операций, такой что
  - она эквивалентна корректному последовательному выполнению операций над одной копией данных (чтение возвращает последнее записанное значение)
  - порядок операций согласуется с временами выполнения операций

Линеаризуемость (менее формально)

- С точки зрения клиентов система работает так, как будто
  - есть только одна копия данных
  - операции атомарны (операция выполняется мгновенно в некоторой момент времени между ее вызовом и завершением)
- Все клиенты видят операции в одном (глобальном) порядке
- Чтение видит результат последней выполненной операции записи

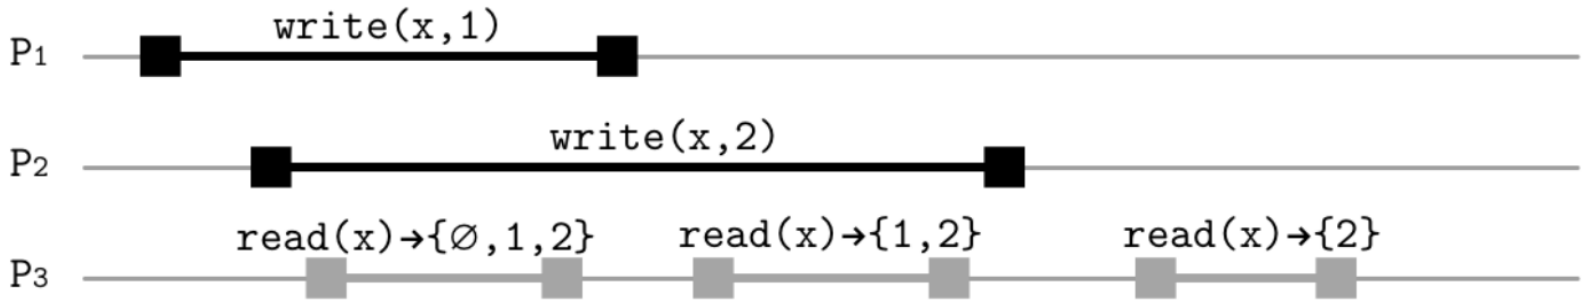

Нарушение линеаризуемости (лидер)

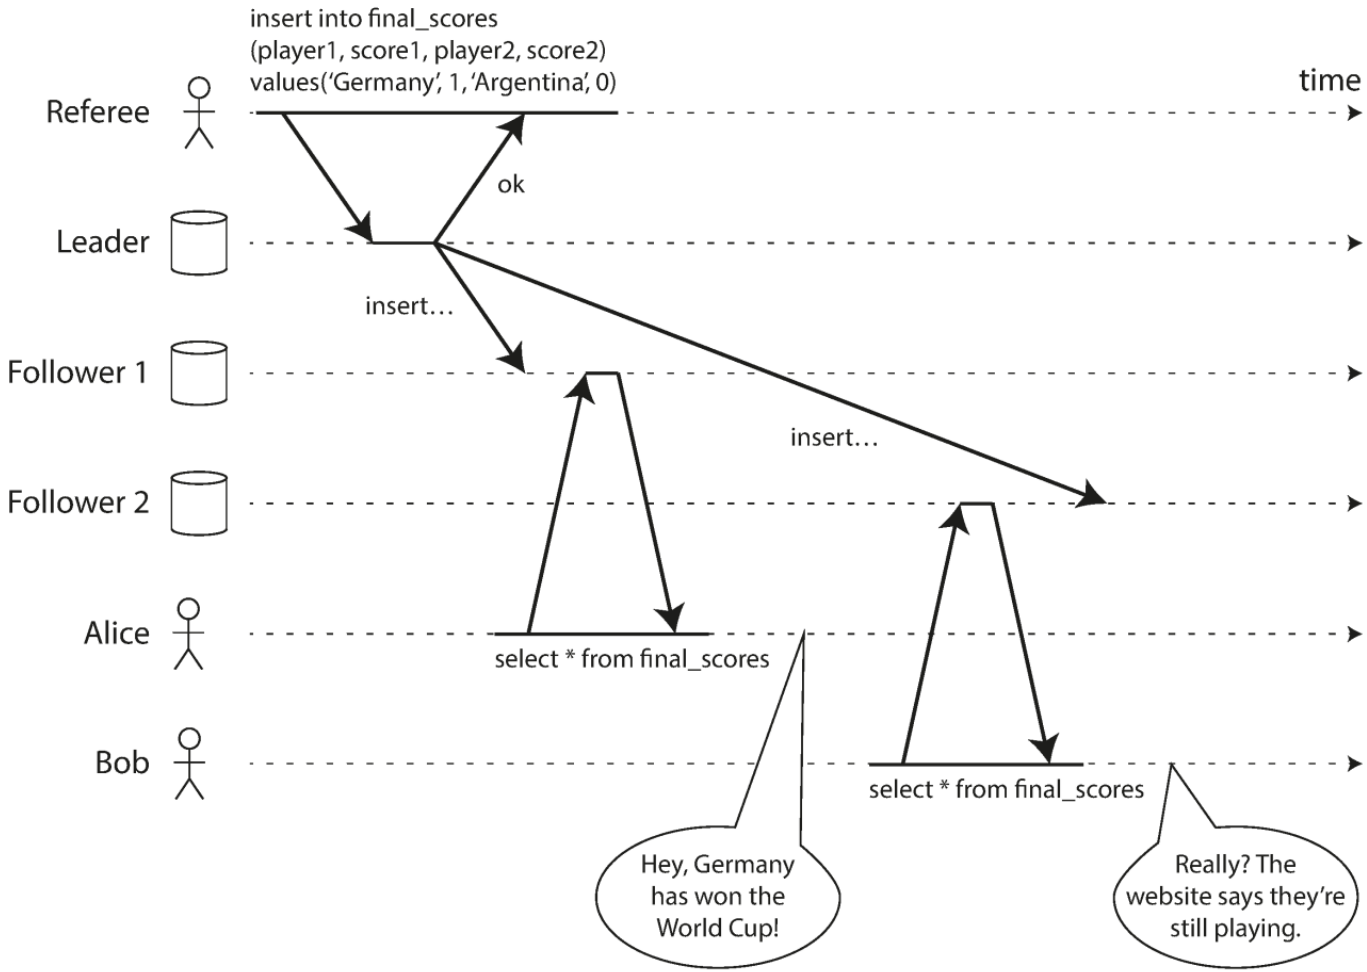

Нарушение линеаризуемости (кворум)

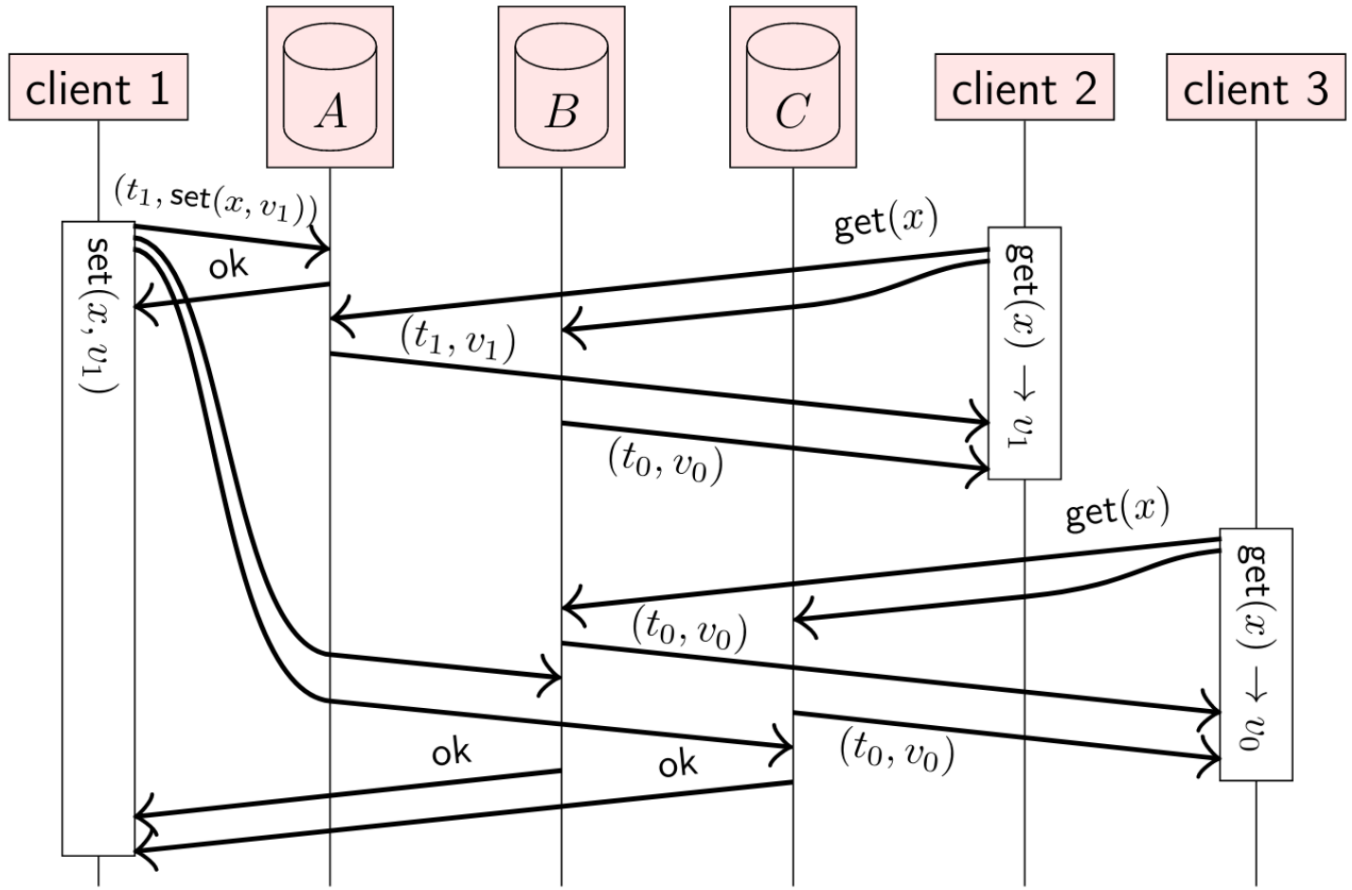

Линеаризуемость

- Преимущества
  - Система ведет себя как нераспределенная (одна копия данных)
  - Упрощает написание клиентских приложений
- Недостатки
  - Уменьшение производительности (много сообщений, ожидание ответов)
  - Ограниченная масштабируемость (лидер - узкое место)
  - Проблемы с доступностью (требуется доступность большинства машин)

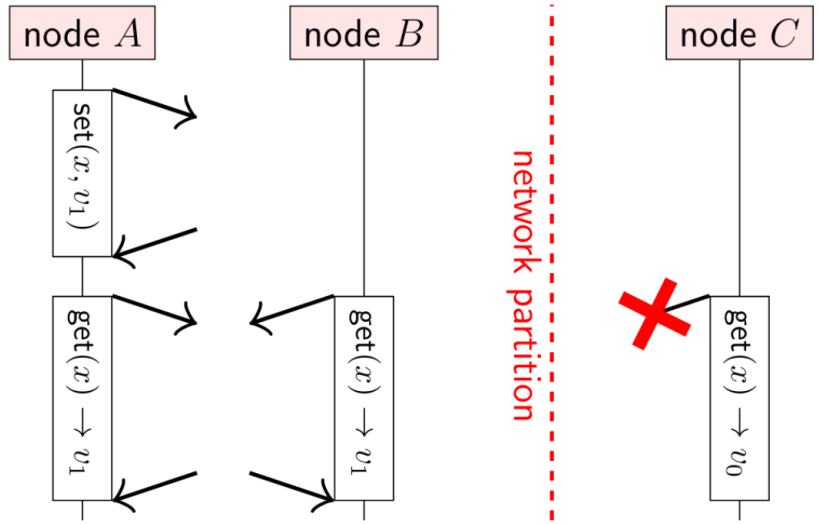

Kleppmann M. A Critique of the CAP Theorem

Согласованность в конечном счёте

> Vogels W. Eventually Consistent (2009)

- "if no new updates are made to an object, eventually all reads will return the last updated value"
- Наиболее слабая из используемых на практике моделей (см. DNS)
- Реплики могут обрабатывать запросы на основе локального состояния
- Ничего не говорит о времени сходимости реплик
- *Strong eventual consistency* гарантирует сходимость реплик
  - каждое изменение рано или поздно достигнет все реплики
  - две реплики, применившие одинаковый набор изменений, придут в одно состояние

Согласованность в конечном счёте

- Преимущества
  - См. недостатки линеаризуемости
  - Лучше производительность, масштабируемость и доступность
- Недостатки
  - Отсутствие привычных гарантий
  - Необходимость разрешения конфликтов
  - Усложнение написания клиентских приложений

Другие модели согласованности

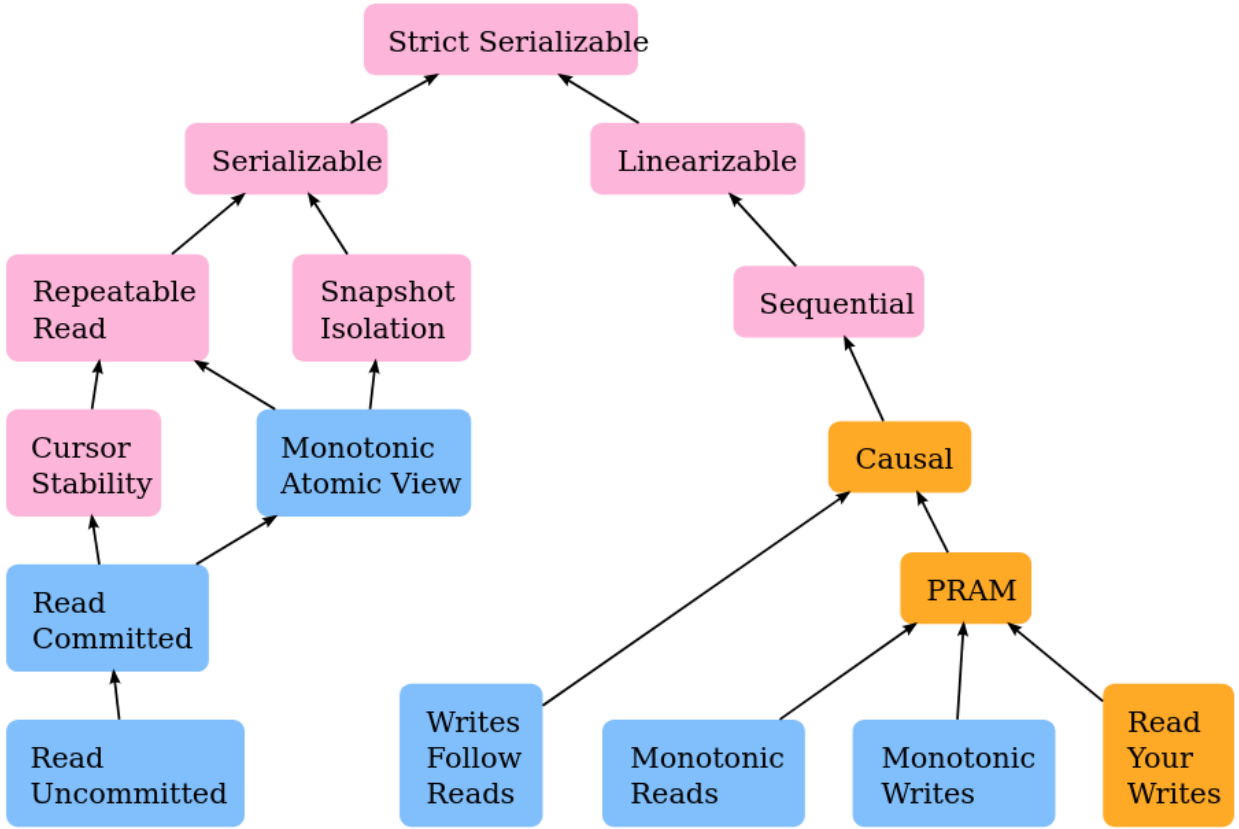

http://jepsen.io/consistency

Последовательная согласованность

> Lamport L. How to Make a Multiprocessor Computer That Correctly Executes Multiprocess Programs (1979)

- Любое выполнение системы может быть представлено в виде некоторой упорядоченной истории операций, такой что
  - она эквивалентна корректному последовательному выполнению операций над одной копией данных
  - порядок операций согласуется с ***порядком выполнения операций*** в каждом из процессов

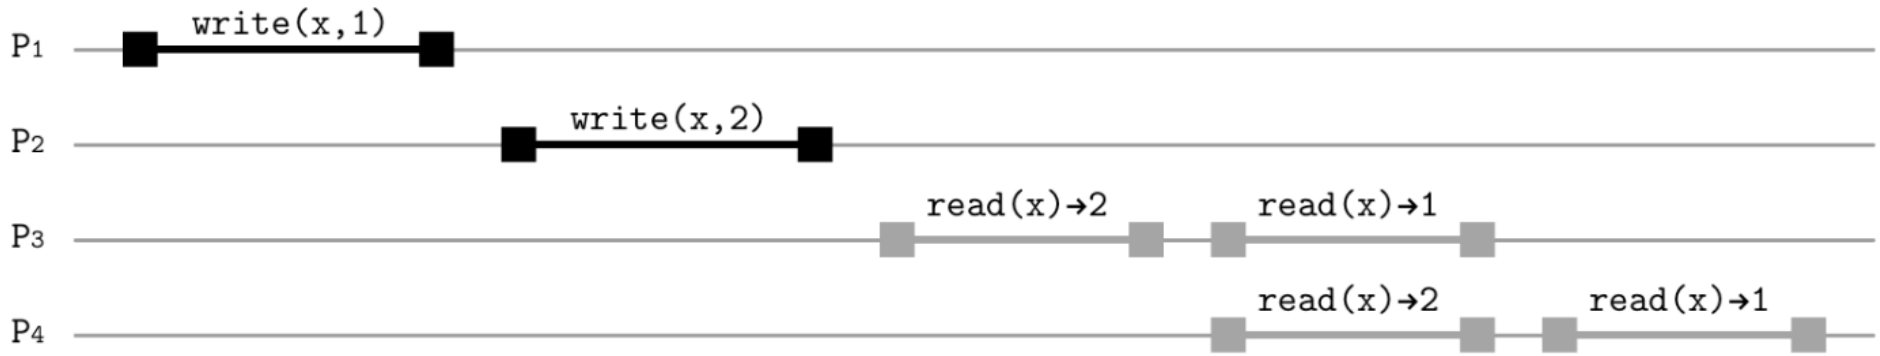

Причинная согласованность

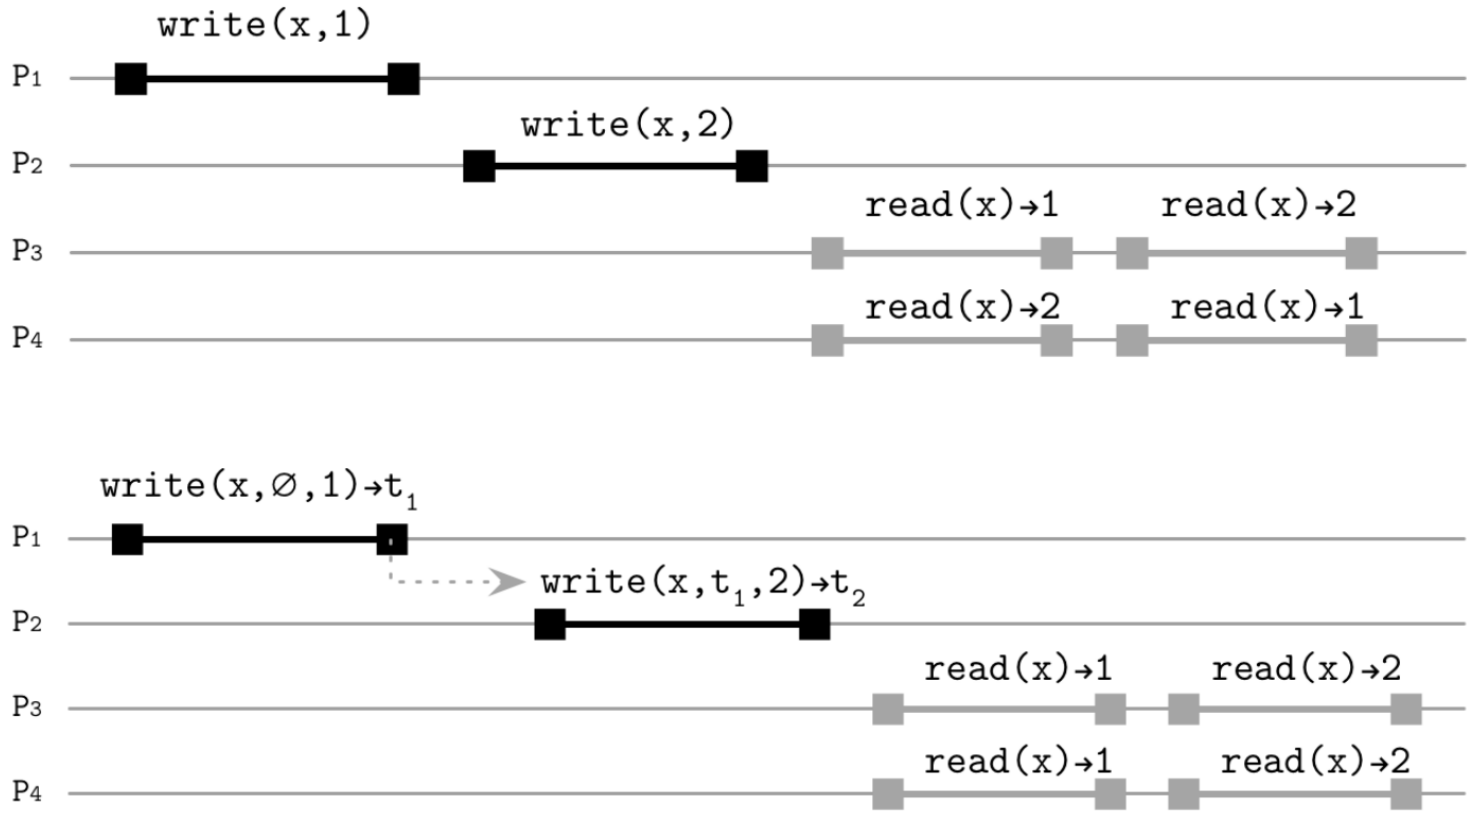

Lloyd W. et al. Don't settle for eventual: scalable causal consistency for wide-area storage with COPS (2011)

Другие модели и гарантии

- Consistent Prefix
  - некоторая часть записей, без пропусков (префикс истории)
- Bounded Staleness
  - все записи, выполненные достаточно давно
- Monotonic Reads
  - увеличивающееся подмножество операций (гарантия на сессию)
- Read After Write (Read Your Writes)
  - все записи, произведенные клиентом (гарантия на сессию)

Terry D. et al. Session Guarantees for Weakly Consistent Replicated Data (1994)

Компромиссы

Guarantee	Consistency	Performance	Availability
Strong Consistency	excellent	poor	poor
Eventual Consistency	poor	excellent	excellent
Consistent Prefix	okay	good	excellent
Bounded Staleness	good	okay	poor
Monotonic Reads	okay	good	good
Read My Writes	okay	okay	okay

Terry D. Replicated data consistency explained through baseball (2011)

Литература

- Kleppmann M. Designing Data-Intensive Applications (глава 5)
- Kleppmann M. Distributed Systems (главы 5 и 7)
- Storti B. A Primer on Database Replication
- Petrov A. Database Internals (глава 11)
- Consistency Models

Литература (дополнительно)

- Упомянутые статьи
- Matei A. CockroachDB's Consistency Model (2019)
- Jepsen: MongoDB stale reads
- Jepsen Analyses